LAB 7 - PaketPro 3000: Yapay Zekâ ve Emniyet

Çıktı: AI Fail-Safe Decision, Evidence Pack EP 03 ve EP 15.

Kavram ve araçlar

Prediction ≠ Safety. YZ tahmin üretir. İnsanı koruyan emniyet mimarisi YZ kararından bağımsız çalışmalıdır.

Fail-safe güvenli davranışı, fallback güvenli işleyişe dönüşü, human override insanın kararı geçersiz kılmasını, monitoring izlemeyi ifade eder. Confidence threshold, altında otomatik kararın kabul edilmediği güven eşiğidir.

Senaryo ve iş akışı

YZ ile görsel paket kontrolü eklenmesi planlanmaktadır. Kamera → YZ modeli → OK / RED → Ret mekanizması → Hat hızı akışı değerlendirilir.

Görev - Üç başarısızlıkta güvenli davranış

1. Model kusurlu parçaya OK verirse ne yapılır?

Kusurlu paket ikinci kontrol veya insan onayıyla ayrılır. Ret sonucu izlenir. Işık perdesi ve çene/bıçak durdurma zinciri YZ kararından bağımsız çalışır.

2. Kamera girdisi bozuk veya sahteyse ne yapılır?

Lens kirliliği ve görüntü kaybı izlenir, kaynak ve veri bütünlüğü kontrol edilir. Şüpheli paket insan kontrolüne ayrılır. Güvenli ayırma yapılamıyorsa hat durdurulur.

3. Modelin güven puanı düşerse ne yapılır?

Eşik, paket kusurlarını kapsayan doğrulama testleriyle belirlenir. Eşik altında otomatik OK verilmez. Paket insan kontrolüne ayrılır, ret arızasında hat güvenli durdurulur.

Karar tablosu - AI Fail-Safe Decision

Başarısızlık	Güvenli davranış ve kavram
Yanlış sınıflandırma	İkinci kontrol ve insan onayı (human override), bağımsız emniyet.
Girdi manipülasyonu	Kaynak/kalite izleme (monitoring), otomatik kabulü engelleme (fail-safe).
Düşük güven puanı	Testlerle belirlenen eşik (confidence threshold), insan incelemesi ve güvenli işleyiş (fallback).

Kaynaklar

• INSPECCO × KRIPTARIUM, PaketPro 3000 LAB Föyleri, LAB 7, PDF s. 8.

• Safety 4.0 Bootcamp Sunumu, PDF s. 24 ve 26.

• Kavramlar Sözlüğü, YZ Güvenliği, PDF s. 3.